

# Destek Vektör Makineleri (SVM)

Makine Öğreniminde  
Güçlü Bir  
Sınıflandırma  
Algoritması

# Giriş



Destek Vektör Makineleri (SVM), güçlü bir sınıflandırma algoritmasıdır.



Verileri en iyi şekilde ayıran bir hiperdüzlem oluşturur.



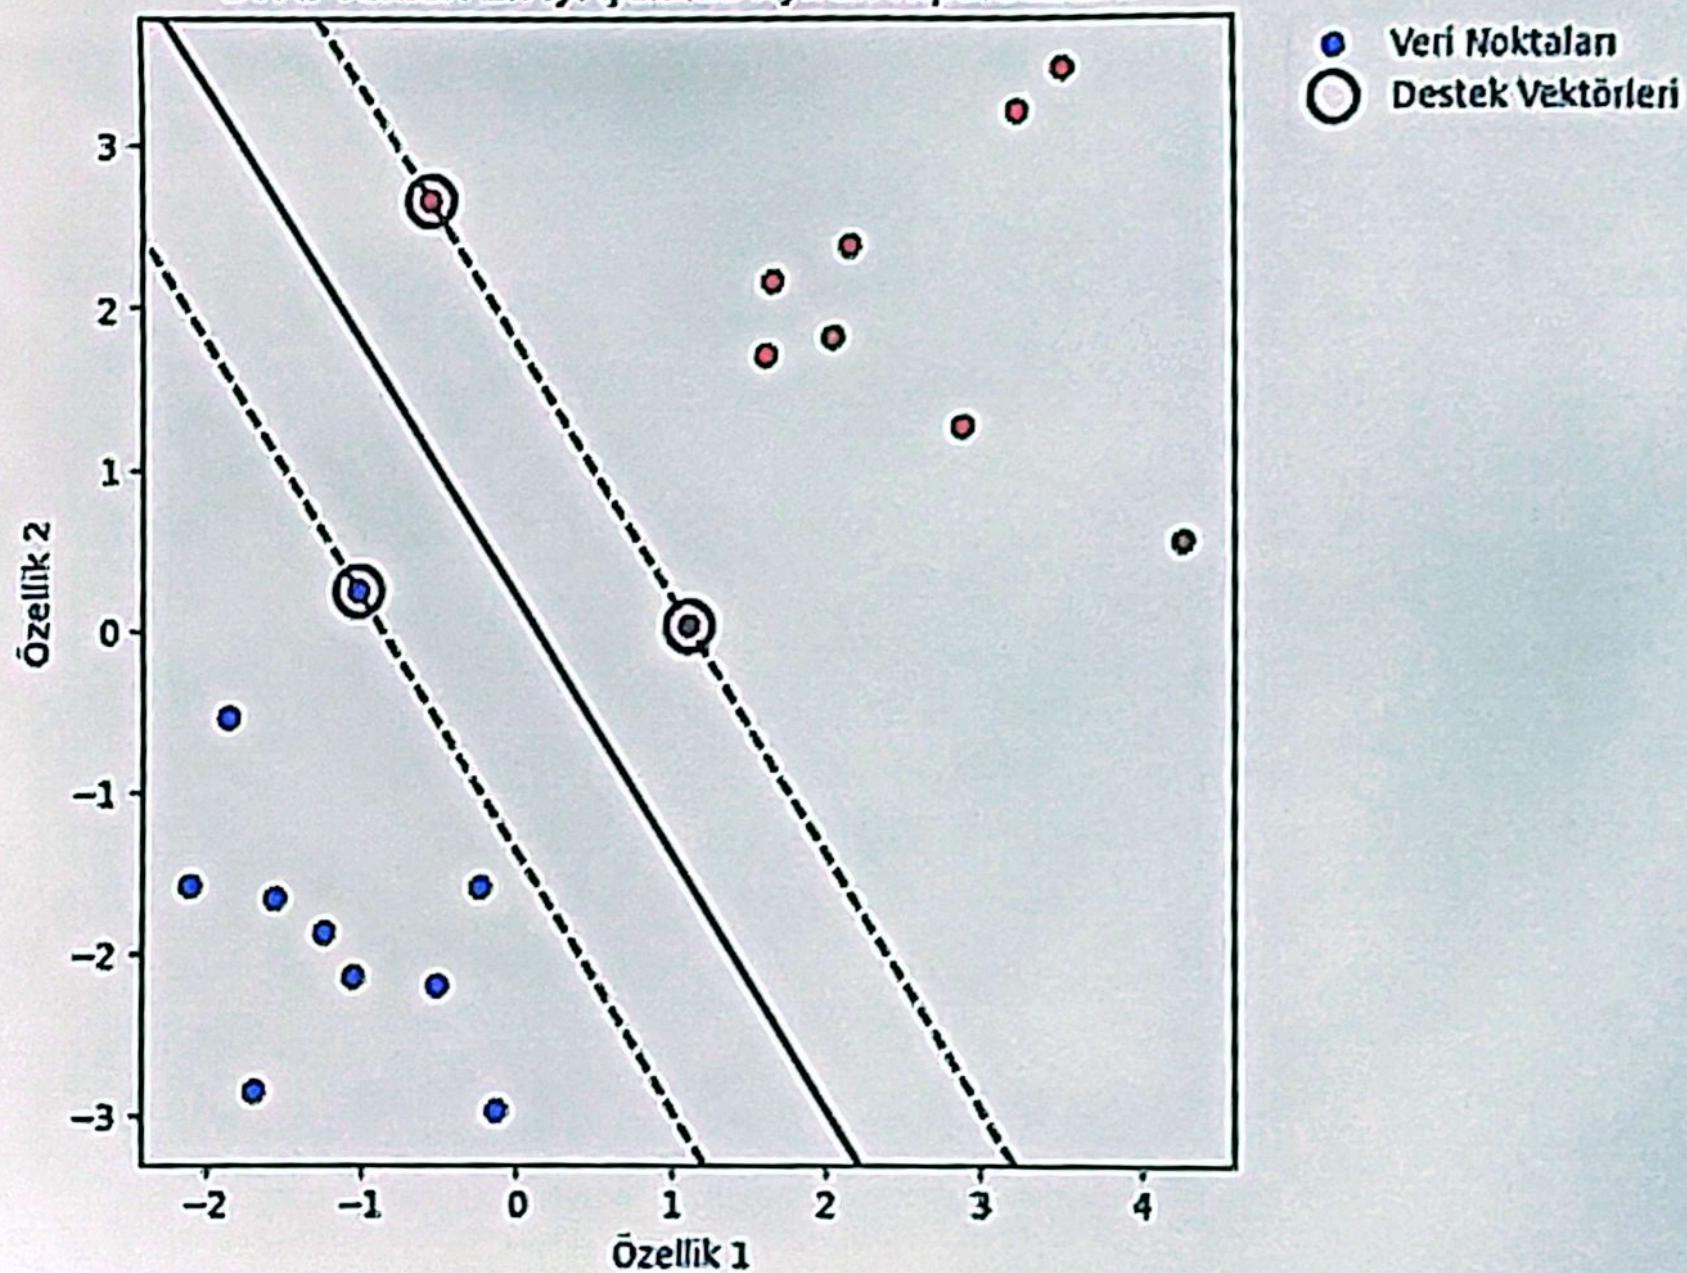
Küçük veri kümelerinde bile iyi genelleştirme yapabilir.



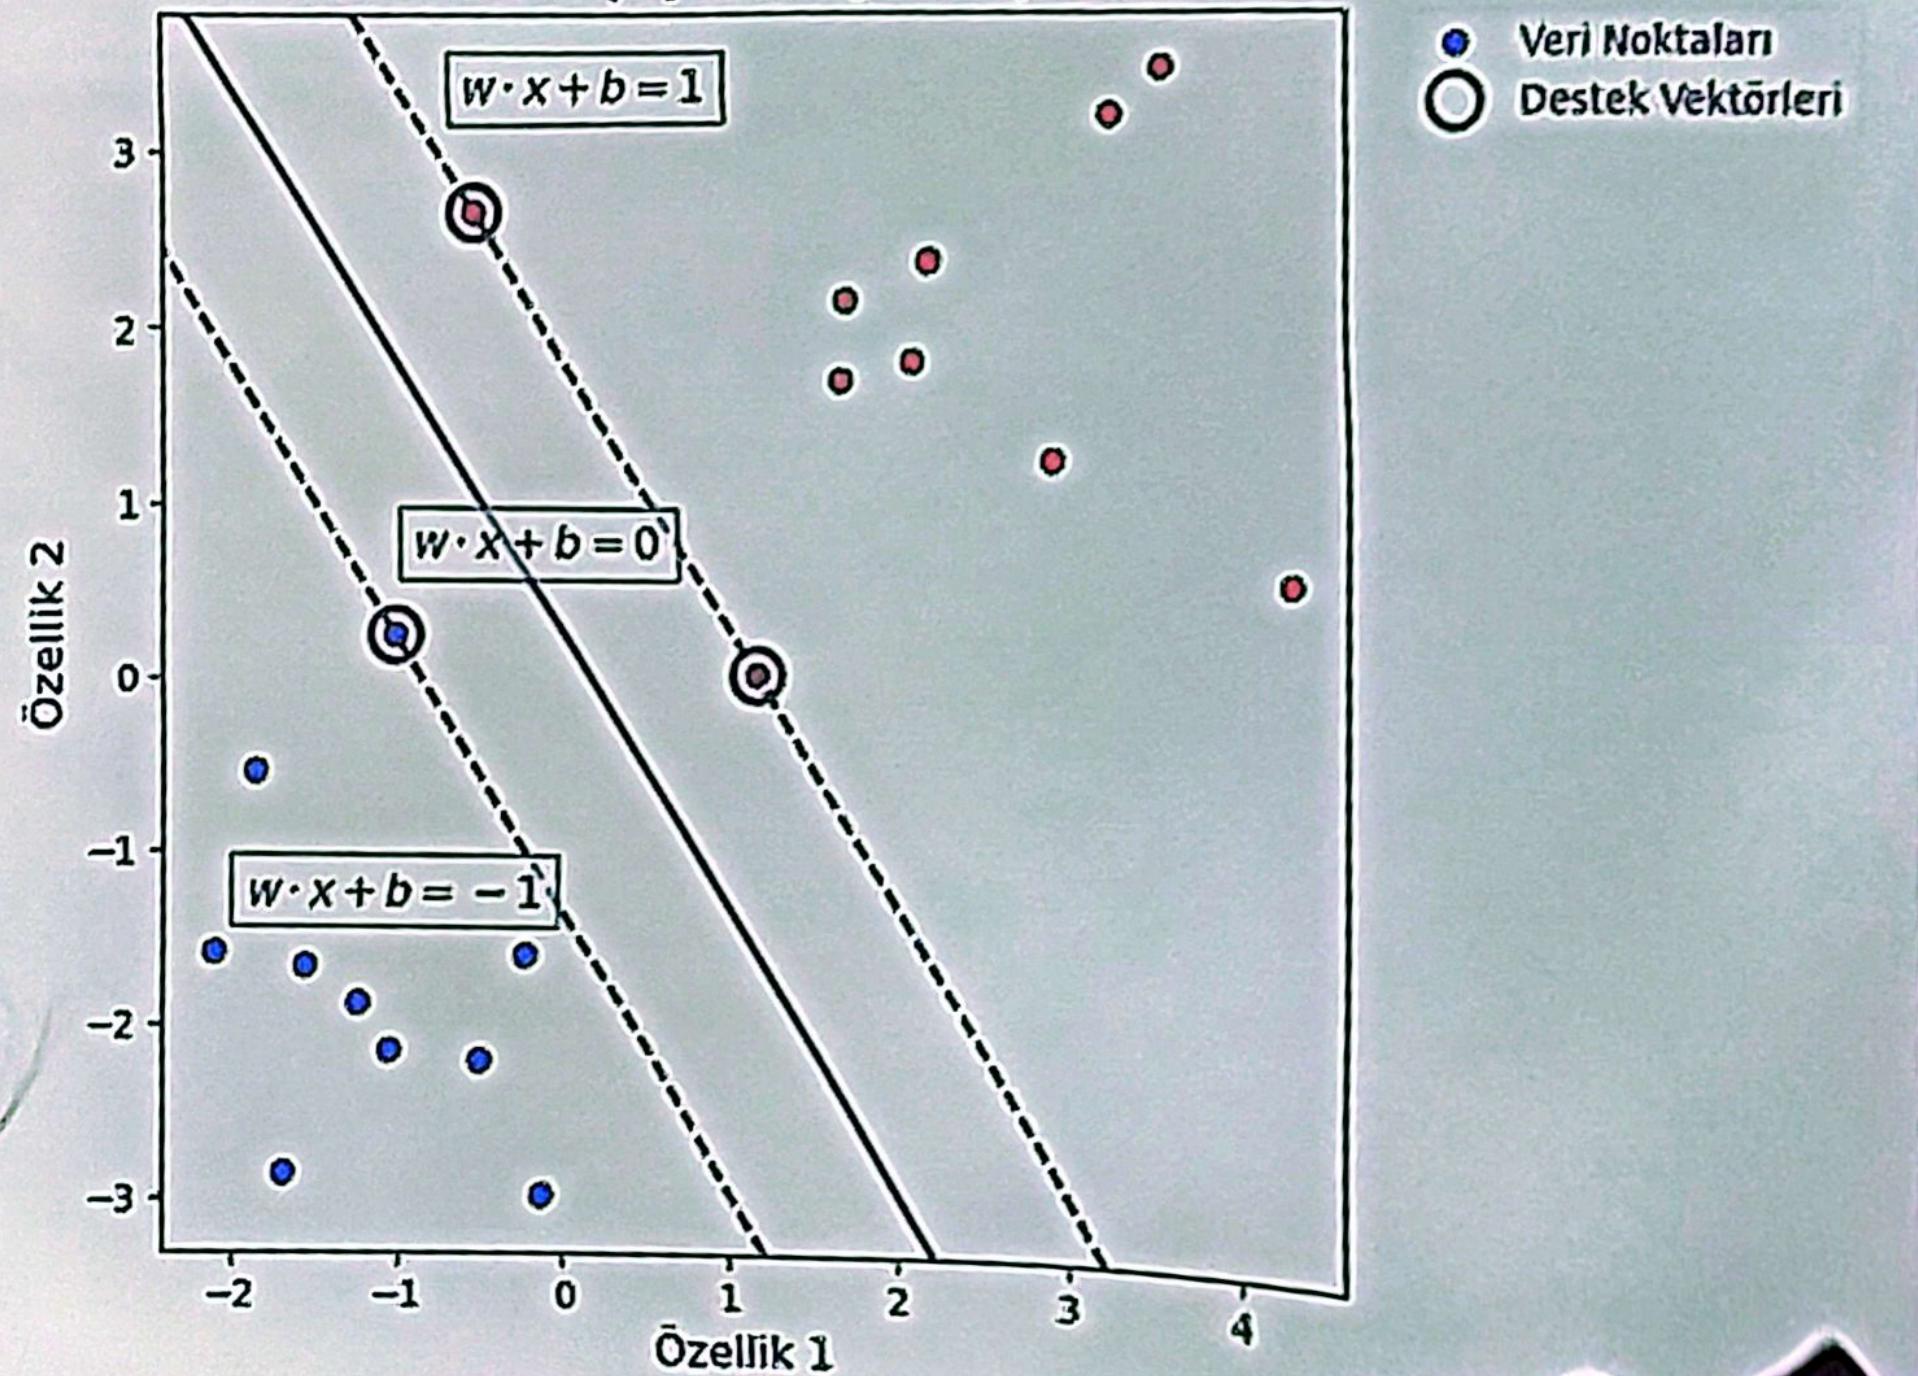
## SVM'in Temel İlkeleri

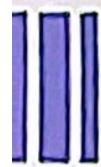
- **Hiperdüzlem (Hyperplane):** Verileri sınıflandıran çizgi veya düzlem.
- **Margin (Marjin):** Hiperdüzleme en yakın veri noktalarına olan mesafe.
- **Destek Vektörleri:** Hiperdüzleme en yakın veri noktalıdır.

## SVM: Verileri En İyi Şekilde Ayıran Hiperdüzlem



## SVM: Verileri En İyi Şekilde Ayıran Hiperdüzlemler





# Hiperdüzlem Denklemi

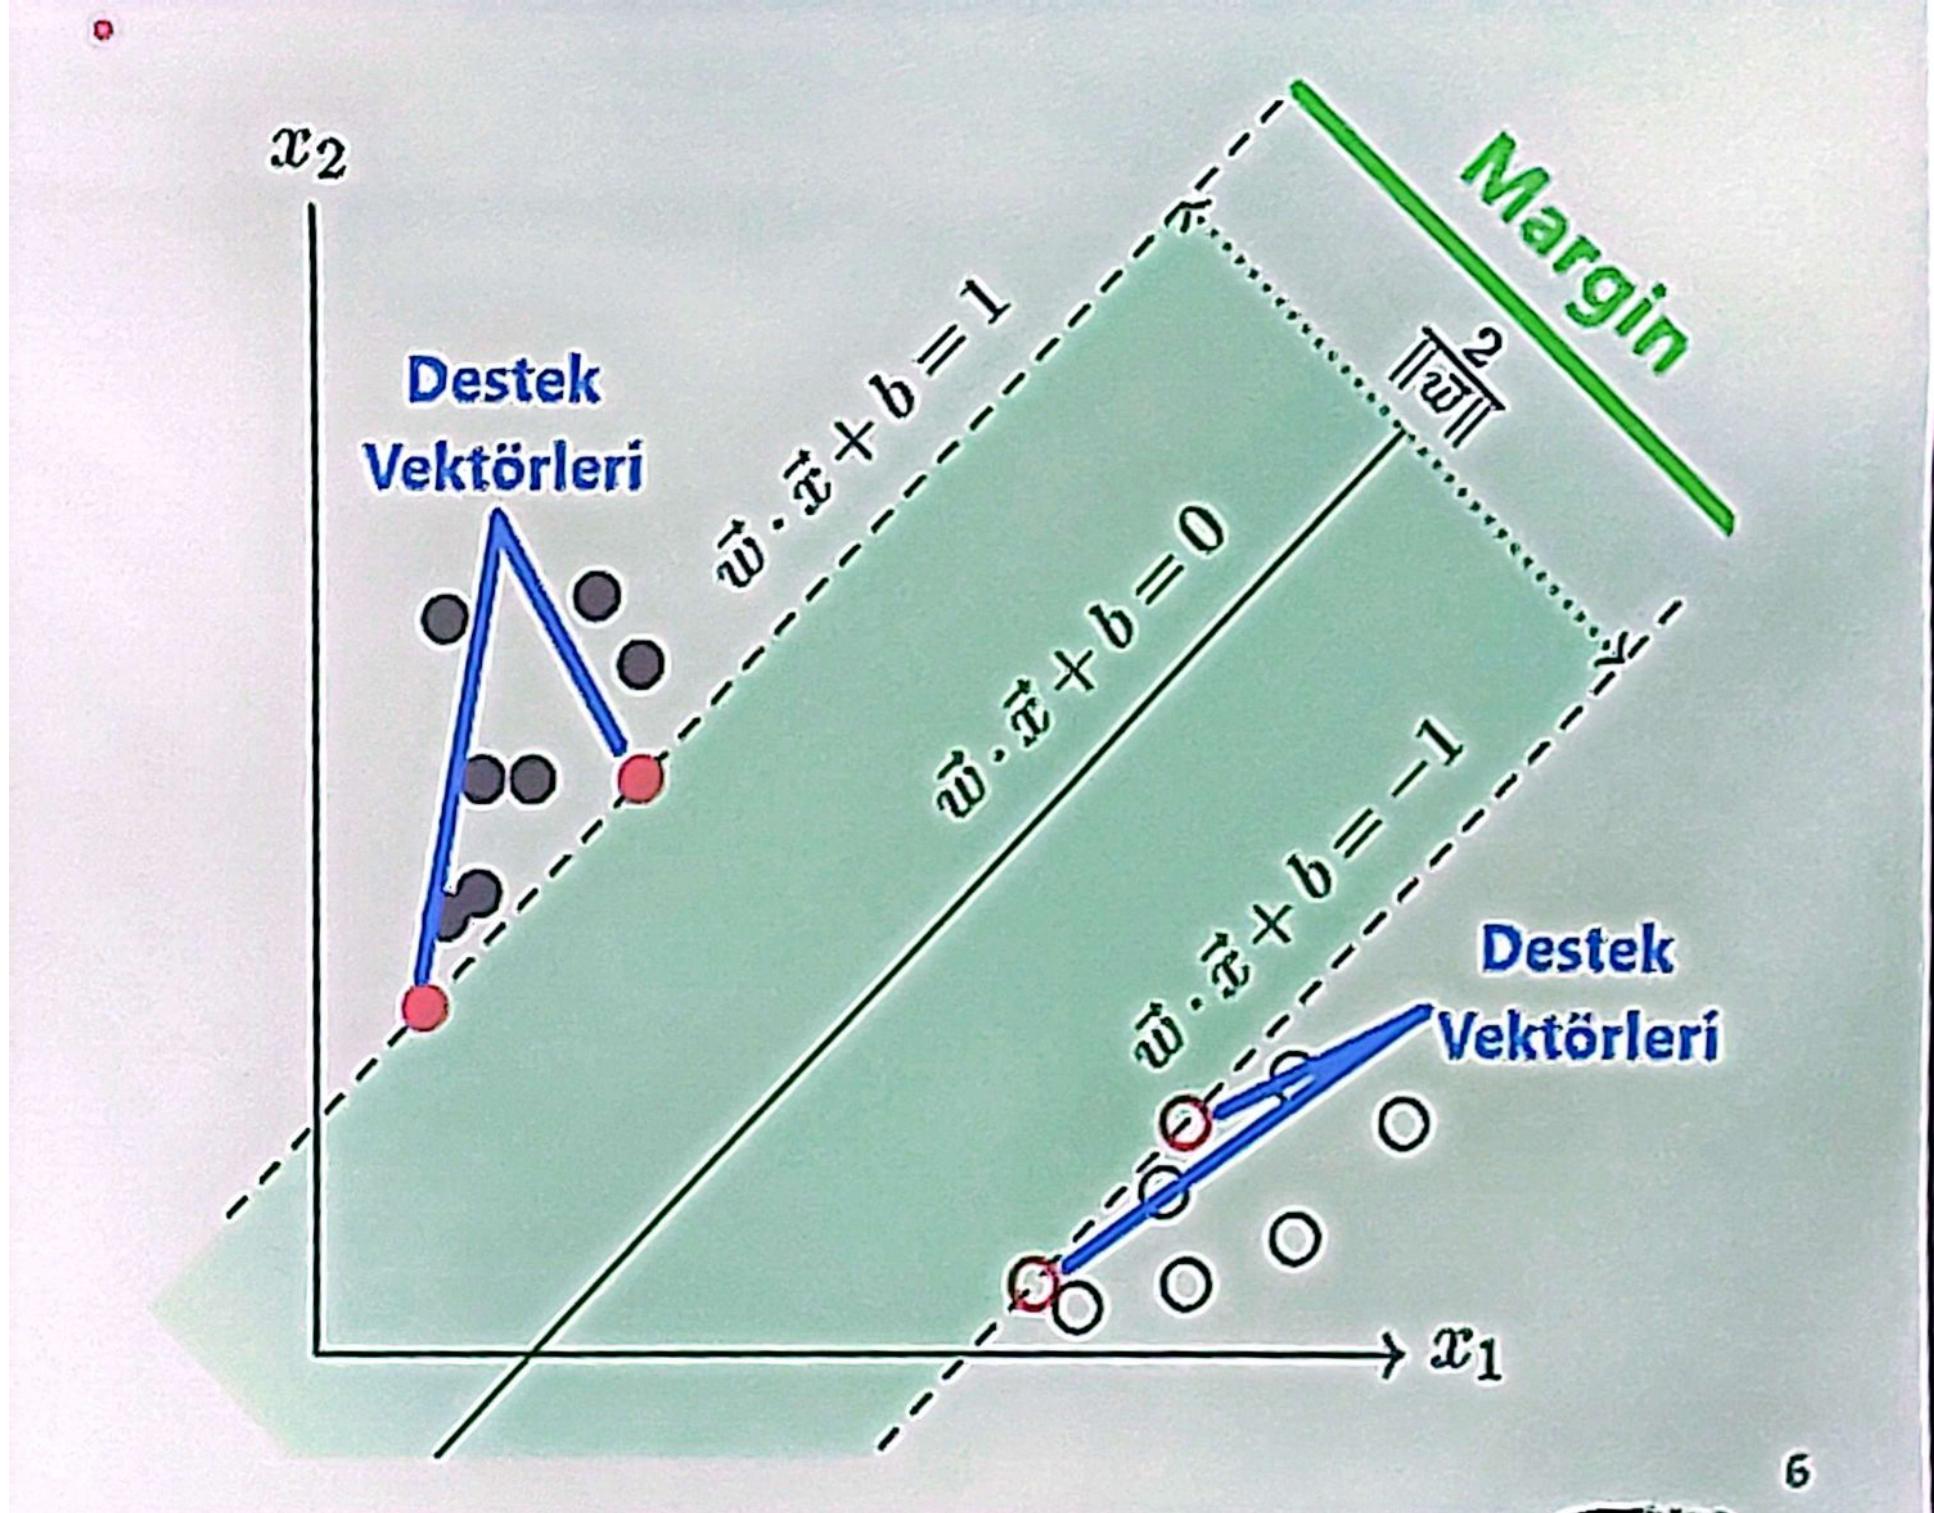
$$w \cdot x + b = 0$$

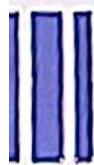
Bu, verileri en iyi şekilde ayıran düzlemini (**hiperdüzlemini**) tanımlar.

Anlamı:

- $w \rightarrow$  Ağırlık vektörü, hiperdüzlemin yönünü belirler.
- $x \rightarrow$  Veri noktası (vektör)
- $b \rightarrow$  Bias (kaydırma terimi), hiperdüzlemin konumunu ayarlar.
- $w \cdot x \rightarrow$  İç çarpım, veri noktasının hiperdüzleme olan ilişkisini hesaplar.

Hiperdüzlem verileri iki sınıfa ayıran sınır çizgisidir.





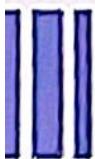
# Margin Denklemleri

$$w \cdot x + b = \pm 1$$

Bu iki denklem, hiperdüzlemden eşit uzaklıkta bulunan iki paralel çizgiyi (marjları) ifade eder.

Anlamı:

- $w \cdot x + b = +1 \rightarrow$  Pozitif sınıfı ait noktaların bulunduğu marj çizgisi
- $w \cdot x + b = -1 \rightarrow$  Negatif sınıfı ait noktaların bulunduğu marj çizgisi
- Bu iki çizgi arasında veri noktası olmaması istenir, sadece destek vektörleri bulunur.
- Amaç, bu iki marj çizgisi arasındaki mesafeyi maksimum yapmak. Böylece genelleşme gücü yüksek bir model elde edilir.



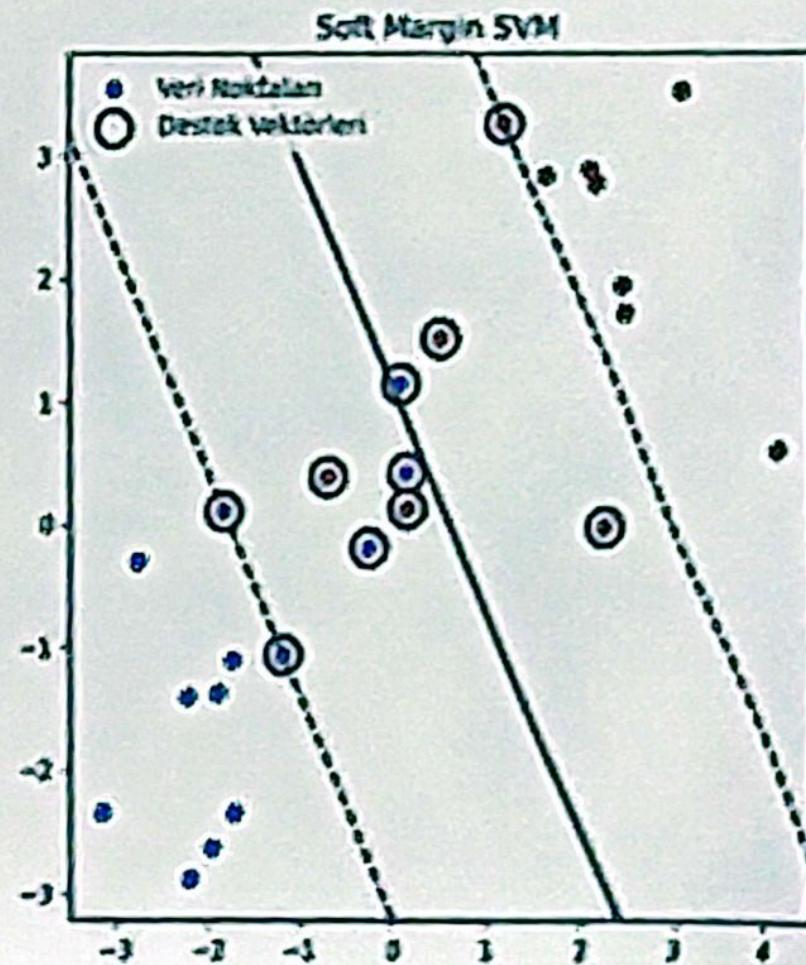
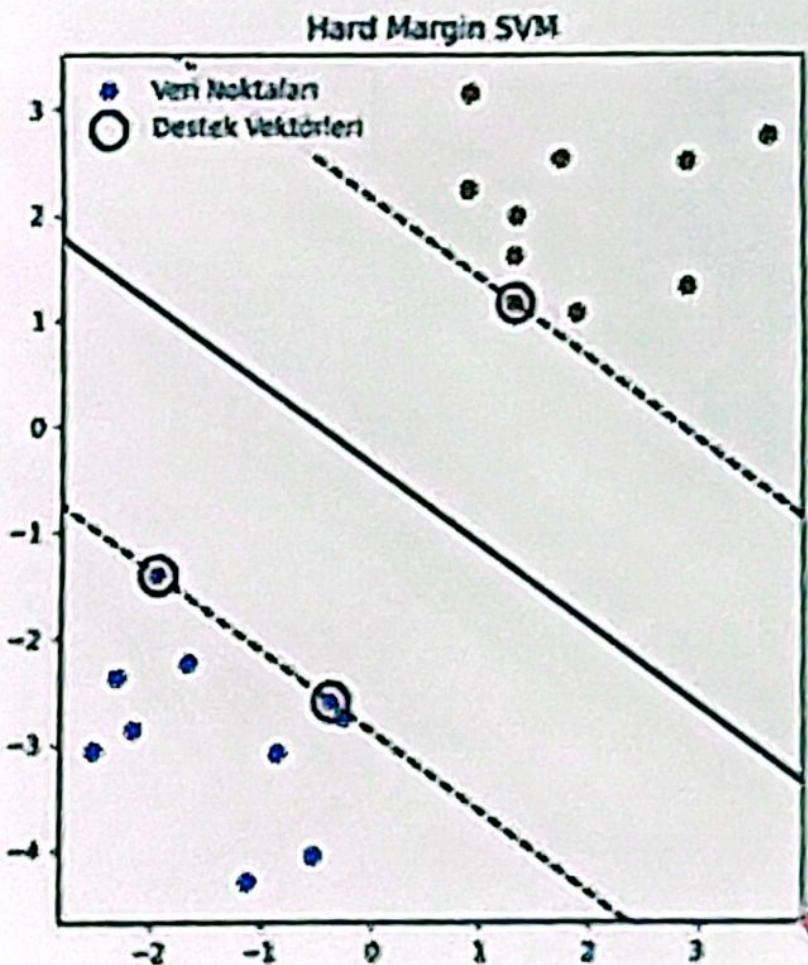
# Margin Genişliği

$$\frac{2}{\|w\|}$$

Bu formül, iki margin çizgisi arasındaki mesafeyi hesaplar.

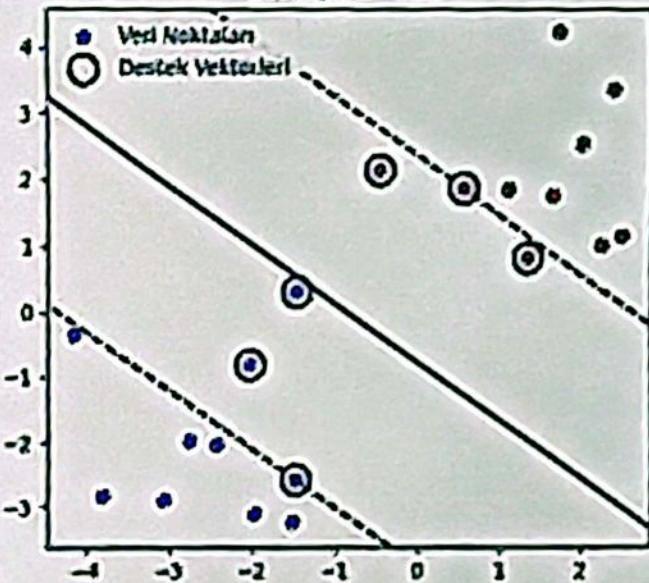
- $\|w\| \rightarrow$  Ağırlık vektörünün normu (büyüklüğü)
- Margin ne kadar büyük olursa, sınıflar daha iyi ayrılmış olur.

# Hard ve Soft Margin

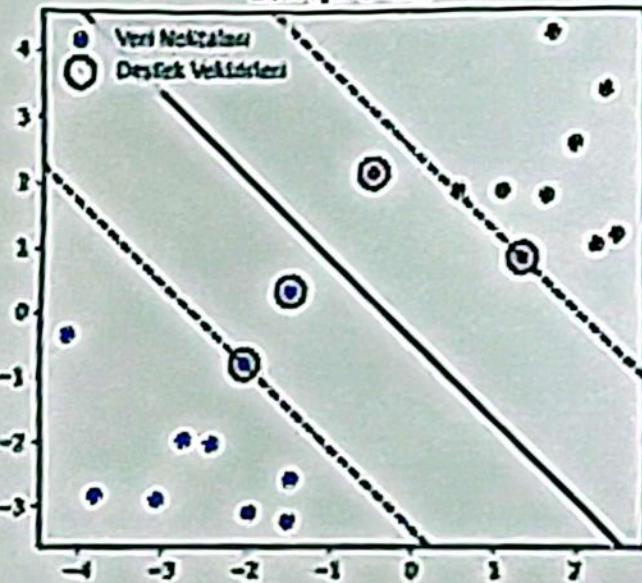


# Hard ve Soft Margin

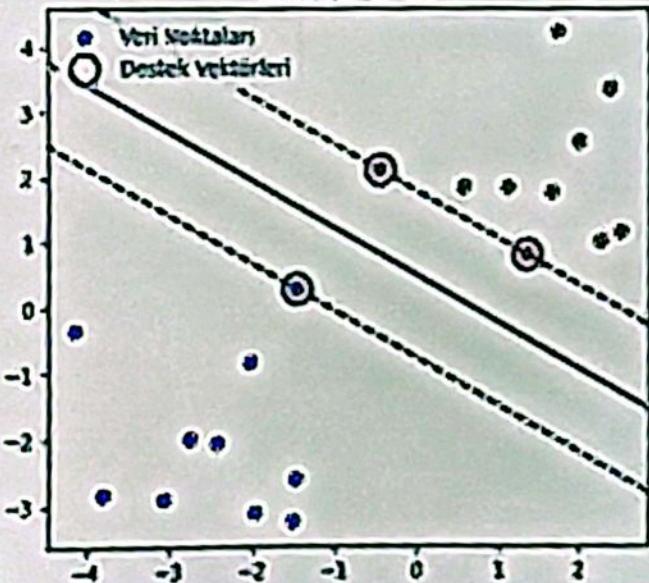
SVM için  $C=0.05$



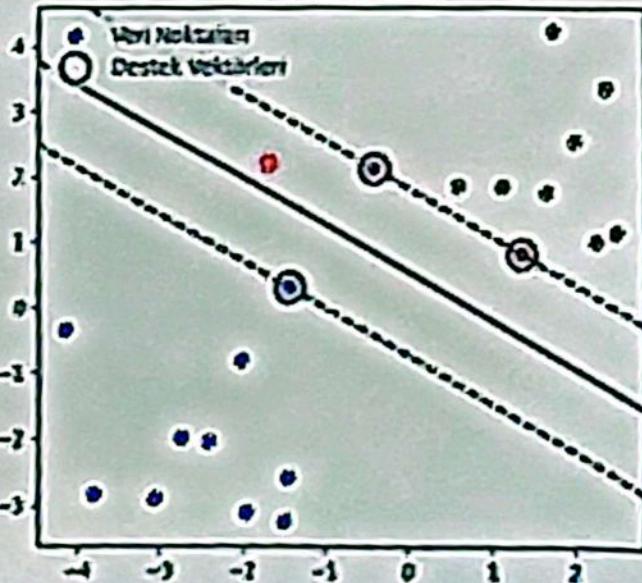
SVM için  $C=0.1$



SVM için  $C=10$



SVM için  $C=1000$

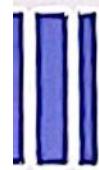




# Doğrusal ve Doğrusal Olmayan SVM

- **Doğrusal SVM:** Veriler doğrusal olarak ayrılabiliriyorsa hiperdüzlem bulunur.
- **Doğrusal Olmayan SVM:** Çekirdek fonksiyonları (kernel trick) kullanılır.



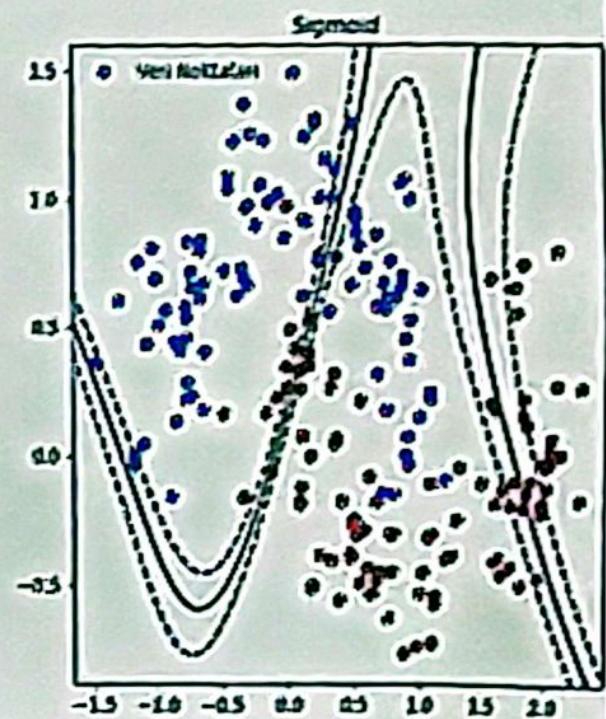
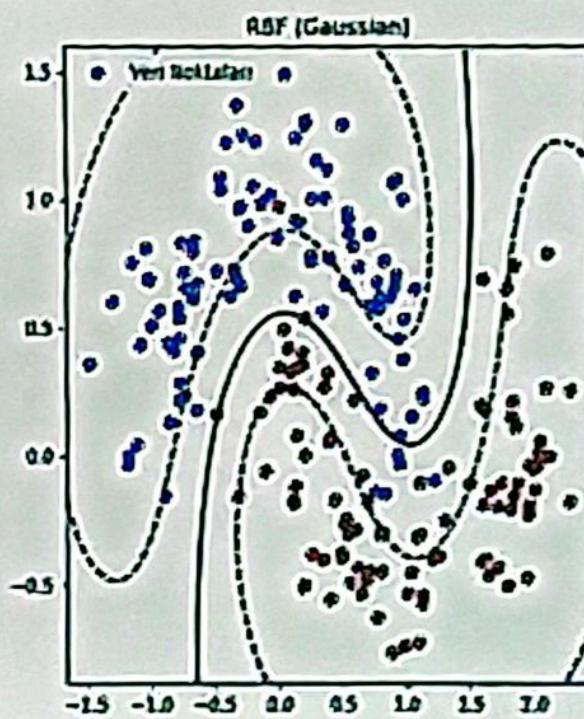
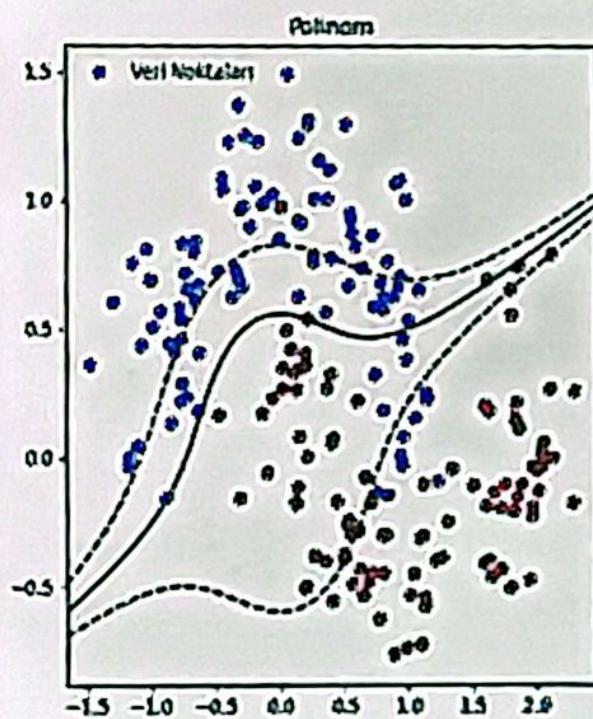


# Çekirdek Fonksiyonları (Kernel Trick)

- Doğrusal (Linear Kernel)
- Polinom (Polynomial Kernel)
- RBF (Radial Basis Function)
- Sigmoid Kernel



# Doğrusal Olmayan SVM



# SVM'in Avantajları ve Dezavantajları

## Avantajlar:

- Küçük veri kümelerinde yüksek doğruluk.
- Marji maksimize ederek genelleştirme kabiliyeti yüksek.
- Çekirdek fonksiyonları ile karmaşık problemleri çözebilir.

## Dezavantajlar:

- Büyük veri kümelerinde eğitim süresi uzun olabilir.
- Parametre ayarlaması zordur.
- Aşırı öğrenme (overfitting) riski vardır.

# Gerçek Dünya Uygulamaları



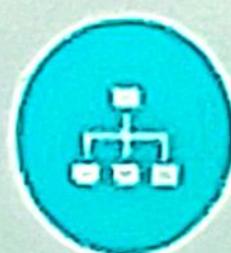
- GÖRÜNTÜ İŞLEME:  
YÜZ TANIMA  
SİSTEMLERİ.



- BIYOINFORMATİK:  
GENETİK VERİ  
ANALİZİ.



- FINANS:  
SAHTEKARLIK  
TESPİTİ.



- METİN  
SİNİFLANDIRMA:  
SPAM TESPİTİ.